

# Restoran Bahşıřlerinin Makine Öğrenimi ile Tahmini ve Müřteri Segmentasyonu

## Predicting Restaurant Tips and Customer Segmentation with Machine Learning

Ahmet Yusuf İnci<sup>1</sup>, Ömer Ömer<sup>2</sup>, Uğur Dinç<sup>3</sup>, Zeynep Sena Tařolar<sup>4</sup>

<sup>1234</sup>*İstanbul Esenyurt Üniversitesi, Mühendislik Mimarlık Fakóltesi, Bilgisayar Mühendislięi Bölümü, İstanbul Türkiye*

### Özet

Bu çalışmada, restoran müşterilerinin bahşıř verme davranıřlarının analiz edilmesi amacıyla denetimli ve denetimsiz makine öğrenmesi yöntemleri birlikte kullanılmıřtır. Analizlerde Seaborn kütüphanesinde yer alan Tips veri seti kullanılmıř; veri seti üzerinde gerekli ön işleme adımları uygulanarak kategorik deęişkenler sayısal formata dönüřtürölmüřtür. Bahşıř miktarının tahmini için Linear Regression ve Random Forest Regressor modelleri uygulanmıř, modellerin performansı  $R^2$  (R-kare) metrięi ile deęerlendirilmiřtir. Elde edilen sonuçlara göre Linear Regression modeli 0.4429  $R^2$  deęeri ile Random Forest modeline kıyasla daha yüksek bir tahmin başarıısı göstermiřtir. Random Forest Regressor modeli ise 0.2436  $R^2$  skoru elde etmiřtir. Ayrıca, müşteri davranıřlarını daha iyi anlayabilmek amacıyla K-Means kümeleme algoritması kullanılarak müşteriler üç farklı segmente ayrılmıřtır. Kümeleme sonuçları, müşterilerin harcama ve bahşıř davranıřlarının belirgin řekilde farklılařtıęını ortaya koymuřtur. Çalışma sonucunda, bu veri seti özelinde doęrusal regresyon yaklařımının daha uygun olduęu görölmüř ve müşteri segmentasyonunun işletmeler için stratejik karar destek mekanizması olarak kullanılabileceęi deęerlendirilmiřtir.

**Anahtar Kelimeler:** Makine Öğrenimi, Regresyon Analizi, Random Forest, K-Means Kümeleme, Bahşıř Tahmini, Müřteri Segmentasyonu.

### Abstract

This study uses a combination of supervised and unsupervised machine learning methods to analyze the tipping behavior of restaurant customers. The Tips dataset from the Seaborn library was used for the analysis; categorical variables were converted to numerical format after applying necessary preprocessing steps. Linear Regression and Random

Forest Regressor models were applied to predict tip amounts, and their performance was evaluated using the  $R^2$  (R-squared) metric. According to the results, the Linear Regression model showed a higher prediction accuracy with an  $R^2$  value of 0.4429 compared to the Random Forest model. The Random Forest Regressor model obtained an  $R^2$  score of 0.2436. Furthermore, to better understand customer behavior, customers were segmented into three different groups using the K-Means clustering algorithm. The clustering results revealed significant differences in customer spending and tipping behaviors. In conclusion, the linear regression approach was found to be more suitable for this dataset, and customer segmentation was evaluated as a strategic decision support mechanism for businesses.

**Keywords:** Machine Learning, Regression Analysis, Random Forest, K-Means Clustering, Tip Prediction, Customer Segmentatio

## 1. Giriş (Introduction)

Dünya’da hizmet sektöründe bahşiş, bir ödeme şekli olarak ortaya çıkmış ve zamanla kültürel bir olgu haline gelerek dünyaya yayılmıştır. Ancak, Çin ve Japonya gibi bazı Doğu ülkelerinde bahşiş kültürü, turistik yerler haricinde hoş karşılanmamaktadır. Türkiye’de de hizmet sektörünün büyümesiyle bahşiş, hem çalışanlar hem de işletmeler için daha önemli bir hale gelmiştir. Restoranlara bırakılan bahşiş miktarı; müşteri memnuniyeti, ekonomik durum, hizmet kalitesi ve ülke kültürü gibi birçok faktöre bağlı olarak şekillenmektedir (Mörel, 2018).Günümüz hizmet sektöründe makine öğrenme yöntemleri, müşteri davranışını öngörmek ve ölçmek için geleneksel istatistik yöntemlerine kıyasla daha güçlü araçlar sağlamaktadır. Bu çalışmanın temel amacı, veri madenciliği yöntemleri ile restoran sahiplerinin ve işletmecilerinin veriye dayalı karar almalarına yardımcı olmaktır. Tahmine dayalı modeller ve sınıflandırma ile verilen bahşiş miktarının tahmin edilmesi sağlanmaktadır. Çalışmamızda, Seaborn “Tips” veri seti üzerinde Lineer Regresyon ve Random Forest Regressor modelleri uygulanarak bahşişi etkileyen değişkenler incelenmiş; ayrıca K-Means algoritması ile müşteri sınıflandırması yapılmıştır. Böylece hem tahmin performansı hem de müşteri profillerine ilişkin çıkarımlar elde edilmiştir.

### 1.1. Çalışmanın Önemi

Hizmet sektöründe hizmet kalitesi, çalışan performansı ve müşteri memnuniyeti bahşiş yardımı ile bir geri bildirim aracıdır. Türkiye’de yapılan çalışmalarda bahşiş uygulamasının, müşterilerin hizmet kalitesini değerlendirme biçimlerinin önemli bir parçası olduğu; özellikle restoran deneyiminde çalışan davranışlarının, hizmet hızı ve işletme atmosferinin bahşiş kararlarını etkilediği belirtilmiştir (Yeşiltaş, Zorlu & Sop, 2018). Bahşiş, gelişen hizmet sektörü sebebiyle işletmeler açısından da tahmini önemli hale gelmiştir. Bahşiş, çalışan motivasyonu, çalışma saatleri ve müşteriye davranış gibi alanlarda işletme sahibine yol gösterebilmektedir. Ayrıca bu sayede müşteriler sınıflandırılarak, farklı müşteri gruplarına uygun hizmet paketleri, kampanyalar ve iletişim stratejileri geliştirilmesine olanak tanır. Restoranlarda bahşiş ile ilgili akademik literatürün incelenmesi ve analizi de önem arz etmektedir (Yılmaz, 2017). Çalışma bu yönüyle restoranlar için pratik öneriler geliştirilmesine yardımcı olacaktır.

### 1.2. Bahşiş Davranışını Etkileyen Faktörler

Türkiye’de bahşiş bırakma davranışı ile ilgili yapılan araştırmalarda, müşterilerin bahşiş kararlarının birçok unsur tarafından belirlendiğini kanıtlamaktadır. Mörel (2018) tarafından yapılan araştırmalarda, bahşiş verilme nedenleri üç grupta toplanmıştır: Beklentsel nedenler, Sosyal nedenler, Duygusal nedenler. Bu çalışma sayesinde, bahşiş davranışının yalnızca ekonomik duruma bağlı olmadığı; müşterinin duygusal tepkileriyle ilişkili olduğunu ortaya koymuştur. Yeşiltaş, Zorlu ve Sop (2018) tarafından Antalya’da yapılan çalışmada, hizmet kalitesinin özellikle güvenilirlik, empati, fiziki koşullar ve çalışan davranışı boyutlarının bahşiş miktarını büyük oranda etkilediği belirtilmiştir. Türkiye’de bahşişin hizmet kalitesini ölçen bir araç olduğu ortaya konulmuştur.

## 2. Materyal ve Yöntem (Material and Method)


### 2.1 Veri Seti Kavramı

Veri seti, makine öğrenmesi algoritmalarının öğrenme sürecini gerçekleştirdiği temel yapı taşıdır. Bir veri seti, satırlarda gözlemleri (örnekleri), sütunlarda ise bu gözlemleri tanımlayan değişkenleri (özellikleri) içermektedir. Denetimli öğrenme problemlerinde veri seti, bağımlı (hedef) değişken ve bağımsız değişkenlerden oluşurken; denetimsiz öğrenmede yalnızca özellikler yer almaktadır. Çetin (2020), veri setinin doğruluğu, tutarlılığı ve temsiliyet gücünün model başarısını doğrudan etkilediğini belirtmektedir.

Gerçek hayat verileri genellikle gürültülü, eksik ve hatalıdır. Bu nedenle veri seti, doğrudan modele verilmeden önce mutlaka analiz edilmeli ve uygun işlemlerden geçirilmelidir.

### 2.1.2 Veri Ön İşleme Aşamaları

Veri ön işleme, ham verinin analiz ve modelleme için uygun hale getirilmesini amaçlayan sistematik bir süreçtir. Hastie, Tibshirani ve Friedman (2009), başarılı bir makine öğrenmesi uygulamasının büyük ölçüde doğru veri ön işleme adımlarına bağlı olduğunu vurgulamaktadır.



**Şekil 1:** Veri işleme basamakları (GeeksforGeeks, Data Preprocessing in Data Mining).

**Eksik Veri Analizi:** Eksik değerler veri toplama hataları veya gözlem eksikliğinden kaynaklanabilir. Eksik veriler silinebilir ya da ortalama, medyan veya mod gibi istatistiksel yöntemlerle doldurulabilir. **Aykırı Değer Tespiti:** Aykırı değerler modelin genelleme yeteneğini olumsuz etkileyebilir. Kutu grafikleri ve z-skoru gibi yöntemlerle tespit edilerek veri setinden çıkarılabilir.

**Veri Dönüştürme:** Kategorik değişkenler sayısal forma dönüştürülür (one-hot encoding vb.).

**Veri Ölçekleme:** Özellikle K-Means ve regresyon algoritmalarında değişkenlerin aynı ölçekte olması gereklidir. Standartlaştırma ve normalizasyon yaygın kullanılan yöntemlerdir.

## 2.2. Kullanılan Modeller

### 2.2.1. Lineer Regresyon

Lineer Regresyon, bağımlı bir değişken ile bir veya birden fazla bağımsız değişken arasındaki doğrusal ilişkiyi modelleyen en temel denetimli öğrenme yöntemlerinden biridir. İstatistiksel temellere dayanan bu yöntem, en küçük kareler (Least Squares) yaklaşımı ile hata kareleri toplamını minimize etmeyi amaçlar (Hastie et al., 2009).


Matematiksel olarak model şu şekilde ifade edilir:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

Bu denklemde  $\beta$  katsayıları bağımsız değişkenlerin etkisini,  $\varepsilon$  ise rastgele hata terimini temsil etmektedir. Lineer regresyon modelinin geçerli olabilmesi için bazı varsayımların sağlanması gerekir:

- Değişkenler arasında doğrusal ilişki
- Hata terimlerinin normal dağılıma sahip olması
- Değişen varyans (homoskedastisite)
- Bağımsız hata terimleri

Lineer regresyon; satış tahmini, fiyat analizi, talep öngörüsü ve müşteri harcama davranışlarının modellenmesi gibi birçok alanda kullanılmaktadır (Çetin, 2020). Yöntemin en önemli avantajı yorumlanabilirliğinin yüksek olmasıdır. Ancak doğrusal olmayan ilişkileri modelleyememesi ve aykırı değerlere duyarlı olması önemli sınırlılıklarıdır.



**Şekil 2:** Lineer regresyon doğrusu ve gözlem noktalarının görsel gösterimi. (GeeksforGeeks, Linear Regression in Machine learning).

### 2.2.2 Random Forest Regressor

Random Forest, Leo Breiman (2001) tarafından geliştirilen ve çok sayıda karar ağacının bir araya getirilmesiyle oluşturulan güçlü bir topluluk öğrenme (ensemble learning) yöntemidir. Bu yaklaşımın temel amacı, tek bir karar ağacının yüksek varyans ve aşırı öğrenme (overfitting) gibi dezavantajlarını azaltarak daha genellenebilir ve kararlı tahminler elde etmektir. Random Forest, istatistiksel öğrenme teorisi kapsamında "bagging" (bootstrap aggregating) tekniğine dayanmaktadır. Bu teknikte, orijinal veri setinden rastgele örnekleme ile oluşturulan alt veri setleri üzerinde ayrı ayrı modeller eğitilir ve bu modellerin çıktıları birleştirilir (Breiman, 2001).


Algoritmanın çalışma süreci aşağıdaki adımlardan oluşmaktadır:

- Veri setinden tekrar seçmeye izin veren rastgele örnekleme (bootstrap) ile alt veri setleri oluşturulur.
- Her bir alt veri seti üzerinde bir karar ağacı eğitilir.
- Ağaç oluşturulurken her düğümde, tüm değişkenler yerine rastgele seçilen sınırlı sayıda özellik kullanılır.
- Regresyon problemlerinde, tüm ağaçların ürettiği tahminlerin ortalaması alınarak nihai tahmin elde edilir.

Bu yapı sayesinde Random Forest, hem varyansı düşürmekte hem de doğrusal olmayan ve karmaşık ilişkileri başarıyla modelleyebilmektedir.

- Doğrusal olmayan ilişkileri yüksek doğrulukla modelleyebilir
- Gürültülü ve büyük veri setlerinde kararlı sonuçlar üretir
- Aykırı değerlere karar ağaçlarına kıyasla daha dayanıklıdır
- Değişken önem düzeylerini (feature importance) hesaplayabilir

Random Forest regresyon modeli; finansal risk tahmini, müşteri davranış analizi ve talep öngörüsü gibi karmaşık ve doğrusal olmayan problemlerde sıklıkla tercih edilmektedir.



**Şekil 3.** Random Forest algoritmasının karar ağaçlarından oluşan yapısının şematik gösterimi. (GeeksforGeeks, Random Forest Algorithm in Machine Learning).

### 2.2.3. K-Means Kümeleme

K-Means, denetimsiz öğrenme algoritmaları arasında en yaygın kullanılan kümeleme yöntemlerinden biridir. Algoritmanın temel amacı, veri setinde yer alan gözlemleri, benzerliklerine göre K adet kümeye ayırmaktır. Buradaki benzerlik genellikle Öklidyen uzaklık metriği ile ölçülmektedir (Hastie, Tibshirani & Friedman, 2009).

K-Means algoritması, özellikle önceden etiketlenmemiş verilerde gizli yapıları ve örüntüleri ortaya çıkarmak amacıyla kullanılmaktadır.

K-Means algoritması iteratif bir yapıya sahiptir ve aşağıdaki adımlarla çalışır:

1. Küme sayısı (K) kullanıcı tarafından belirlenir.
2. Veri uzayında K adet başlangıç küme merkezi rastgele seçilir.
3. Her gözlem, kendisine en yakın küme merkezine atanır.
4. Küme merkezleri, kendilerine atanmış gözlemlerin ortalaması alınarak güncellenir.
5. Küme merkezleri değişmeyene veya belirlenen iterasyon sayısına ulaşılan kadar süreç devam eder.

Bu süreçte amaç, küme içi varyansı minimize etmektir.

K-Means algoritmasının en kritik noktalarından biri uygun K değerinin seçilmesidir. Literatürde bu amaçla Dirsek (Elbow) yöntemi ve Silhouette analizi yaygın olarak

kullanılmaktadır. Kaya (2019), müşteri segmentasyonu çalışmalarında bu yöntemlerin etkin sonuçlar verdiğini belirtmektedir.


Avantajları:

- Uygulaması kolay ve hesaplama maliyeti düşüktür
- Büyük veri setlerinde hızlı sonuç üretir
- Kümeleme mantığı sezgiseldir

Sınırlılıkları:

- Küme sayısının önceden belirlenmesi gerekir
- Aykırı değerlere ve başlangıç merkezlerine duyarlıdır
- Küresel olmayan (non-spherical) kümelerde başarısı düşer

K-Means algoritması; müşteri segmentasyonu, pazar analizi ve davranışsal veri gruplama çalışmalarında yaygın olarak kullanılmaktadır.




**Şekil 4.** K-Means algoritması ile elde edilen örnek kümeleme sonucu. (GeeksforGeeks, K means Clustering – Introduction).

## 2.2.4 Kullanılan Araçlar

Bu çalışma kapsamında ele alınan makine öğrenmesi modellerinin (Lineer Regresyon, Random Forest Regresyon ve K-Means Kümeleme) uygulanması, model performansı analizi ve elde edilen bulguların görselleştirilmesi için Python programlama dili tercih edilmiştir. Python'un zengin bilimsel kütüphane ekosistemi, veri madenciliği ve istatistiksel analiz görevlerini etkin bir şekilde gerçekleştirmeye olanak tanımıştır. Veri setinin ilk aşamadaki işlenmesi, manipülasyonu ve yapılandırılması için Pandas kütüphanesinden faydalanılmıştır (McKinney, 2010). Pandas, özellikle tablo tabanlı verilerle (DataFrame) çalışmada esneklik ve yüksek performans sunarak veri ön işleme süreçlerinin temelini oluşturmuştur. Analitik bulguların ve model sonuçlarının anlaşılabilirliğini artırmak amacıyla, veri görselleştirmeleri için Seaborn (Waskom, 2021) ve Matplotlib (Hunter, 2007) kütüphaneleri kullanılmıştır. Seaborn, Matplotlib üzerine inşa edilmiş olup, istatistiksel görselleştirmelerin kolay ve estetik bir şekilde oluşturulmasını sağlamıştır. Makine öğrenimi modellerinin inşası, eğitimi ve değerlendirilmesi süreçlerinde ise Scikit-learn kütüphanesinin yeteneklerinden yararlanılmıştır (Pedregosa vd., 2011). Regresyon analizleri için LinearRegression ve RandomForestRegressor sınıfları, kümeleme analizi için ise KMeans sınıfı kullanılarak algoritmalar veri setine uygulanmış ve performans metrikleri hesaplanmıştır.


## 3. Bulgular ve Tartışma (Results and Discussion)

Bu çalışmada, restoran müşterilerinin bahşiş miktarını etkileyen faktörlerin analiz edilmesi amacıyla farklı makine öğrenmesi yaklaşımları kullanılmıştır. Denetimli öğrenme kapsamında Linear Regression ve Random Forest Regressor modelleri uygulanmış; modellerin performansı  $R^2$  (R-kare) metriği kullanılarak değerlendirilmiştir. Elde edilen sonuçlar, Linear Regression modelinin 0.4429  $R^2$  değeri ile Random Forest Regressor modeline (0.2436  $R^2$ ) kıyasla daha yüksek bir tahmin başarısı sunduğunu göstermektedir. Bu durum, bahşiş miktarı ile açıklayıcı değişkenler arasında güçlü doğrusal ilişkilerin bulunduğuna işaret etmektedir. Toplam hesap tutarı ile bahşiş miktarı arasındaki ilişki detaylı olarak incelendiğinde, iki değişken arasında belirgin ve pozitif yönlü bir ilişki olduğu gözlemlenmiştir. Bu ilişki, özellikle görsel analizler aracılığıyla daha net bir şekilde ortaya konmuştur. Şekil 1, toplam hesap tutarı arttıkça bahşiş miktarının da arttığını göstermekte ve Linear Regression modelinin bu veri seti için neden daha başarılı olduğunu desteklemektedir.



**Şekil 5:** Toplam Hesap ve Bahşış Miktarına Göre Üç (K=3) Müşteri Segmenti.


Günlere ve cinsiyete göre bahşış dağılımları incelendiğinde, bahşış davranışlarının haftanın farklı günlerinde değişkenlik gösterdiği görülmüştür. Özellikle hafta sonu günlerinde bahşış miktarlarının daha geniş bir dağılıma sahip olduğu dikkat çekmektedir. Cinsiyet değişkeninin ise bahşış miktarı üzerindeki etkisinin sınırlı olduğu gözlemlenmiştir. Bu durum, demografik faktörlerin tek başına belirleyici olmadığını göstermektedir. Şekil 2, bu dağılımları görsel olarak sunmakta ve bulguları desteklemektedir.



**Şekil 6:** Haftanın Günlerine ve Cinsiyete Göre Bahşış Miktarı Dağılımları (Kutu Grafiği).


Random Forest Regressor modeli kullanılarak elde edilen özellik önemleri analiz edildiğinde, toplam hesap tutarının bahşış tahmininde açık ara en önemli değişken olduğu belirlenmiştir. Masadaki kişi sayısı değişkeni ikincil düzeyde etkili olurken, cinsiyet,

sigara içme durumu, gün ve zaman değişkenlerinin katkısının oldukça sınırlı olduğu görülmüştür. Bu durum, bahşiş davranışının temel belirleyicisinin harcama miktarı olduğunu ortaya koymaktadır. Model tarafından hesaplanan özellik önemleri Şekil 3'te sunulmuştur.



**Şekil 7:** Bahşiş Tahmin Modeli İçin Özellik Önem Skorları.

Denetimsiz öğrenme kapsamında uygulanan K-Means kümeleme analizi sonucunda müşterilerin harcama ve bahşiş davranışlarına göre üç farklı segmente ayrıldığı görülmüştür. Bu segmentler; düşük, orta ve yüksek harcama-bahşiş profillerine sahip müşteri gruplarını temsil etmektedir. Kümeleme sonuçları, müşteri davranışlarının homojen olmadığını ve farklı müşteri profillerinin bulunduğunu açıkça göstermektedir. Elde edilen küme yapısı Şekil 4'te görselleştirilmiştir.



**Şekil 8:** Toplam Hesap ve Bahşiş Miktarına Göre Üç (K=3) Müşteri Segmenti.

Sonu olarak, bu alıřma, regresyon ve kmeleme yntemlerinin birlikte kullanıldıđı btncl bir yaklařım sunmakta ve farklı makine đrenmesi tekniklerinin aynı veri seti zerindeki performanslarını karřılařtırmalı olarak ortaya koymaktadır. Elde edilen bulgular, zellikle restoran iřletmeleri iin mřteri davranıřlarını anlamaya ynelik veri odaklı karar destek mekanizmalarının geliřtirilmesine katkı sađlayabilecek niteliktedir. Gelecek alıřmalarda, daha byk veri setleri, farklı zellik mhendisliđi teknikleri ve alternatif regresyon algoritmaları kullanılarak model performanslarının artırılması ve daha genellenebilir sonular elde edilmesi hedeflenebilir.

### **Kaynaka (References)**

- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- etin, F. (2020). *Veri Madenciliđi ve Mřteri Davranıřlarının Tahmini zerine Bir Uygulama*. İstanbul: [niversite/Enstit Adı], [Yksek Lisans Tezi].
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.
- Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90–95.
- Kaya, H. (2019). *Restoranlarda Mřteri Segmentasyonuna Ynelik Veri Madenciliđi Uygulaması*. Ankara: [niversite/Enstit Adı], [Yksek Lisans Tezi].
- McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 51–56.
- Mrel, S. (2018). *Tketicilerin Bahřıř Verme Davranıřı: Restoran Mřterileri zerinde Bir Arařtırma*. Mersin: Mersin niversitesi Sosyal Bilimler Enstits.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, V., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, . (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Waskom, M. L. (2021). Seaborn: Statistical Data Visualization. *Journal of Open Source Software*, 6(60), 3021.

Yeşiltaş, M., Zorlu, Ö., & Sop, A. (2018). Hizmet Kalitesinin Müşterilerin Bahşış Davranışı Üzerindeki Etkisi. *Uluslararası Sosyal Araştırmalar Dergisi*, 11(56), 1243–1256.

Yılmaz, G. (2017). Restoranlarda Bahşış İle İlgili Yayınlanan Makalelerin Bibliyometrik Analizi. *Seyahat ve Otel İşletmeciliği Dergisi*, 14(2), 65–79.

GeeksforGeeks. (n.d.). K-means clustering algorithm. <https://www.geeksforgeeks.org/k-means-clustering-algorithm/>

GeeksforGeeks. (n.d.). Random Forest Algorithm in Machine Learning. <https://www.geeksforgeeks.org/machine-learning/random-forest-algorithm-in-machine-learning/>

GeeksforGeeks. (n.d.). Linear Regression in Machine learning. <https://www.geeksforgeeks.org/machine-learning/ml-linear-regression/>